



云计算期末项目说明文档

项目背景

我们发现一个有趣的现象，人们总是会对自己感兴趣的话题投入精力。大家经常在小红书刷擦边视频时猝不及防被塞一脑子单词，还有模仿原神世界观解释有机化学等等。我们通过问卷形式进行背景调研发现，学习者面临着两种困境：枯燥的知识理论与网络娱乐的引诱。



图一：学习时遇到的困难



图二：热门IP的了解程度

为了摆脱传统学习方式带来的枯燥乏味，帮助学习者将更多精力投入到专业性知识的学习中，本项目开发了一款名为 **Storming/风暴** 的智能IP类比讲解系统，旨在通过大语言模型来将热门IP内容与枯燥专业知识的结合，帮助用户通过类比IP内容理解专业知识。基于项目要求，该系统采用 `LangChain` 框架与云原生数据库 `weaviate` 实现模型逻辑，同时通过 `Docker` 部署。


设计思路

该应用具有两个方面的设计创新点，个性化与IP化。

一、个性化

- 用户登录与注册

用户可以通过注册和登录功能创建个人账户，支持自定义昵称与头像上传功能。



- 历史记录保存

用户与大模型进行的会话内容将进行长时间保留，作为用户的学习历史记录，方便用户随时复习回顾。该内容将展示在用户个人界面，同时支持分享与展示。

对话历史	
使用宝可梦解释高等数学	2021-10-10 10:00:00
使用游戏《原神》解释软件需求	2021-10-10 10:00:00
使用游戏《植物大战僵尸》解释软件需求	2021-10-10 10:00:00


二、IP化

- IP化讲解

用户输入IP标签以及想要学习的内容，系统根据用户输入从向量数据库中检索相关信息作为大模型增强内容帮助生成讲解内容。同时在当前会话中，通过用户不断地会话反馈，能够对当前知识点进行深入探讨，生成更精细、更完备地知识点内容。



用户使用该系统的流程可以体现为：



未来展望

在未来的项目推进中，我们还拟添加如下功能：

- 学习计划

系统能够根据用户的历史记录，个性化地为用户制定想要学习知识点地学习计划，并且提供每日打卡功能帮助用户按照计划坚持学习。

- 角色扮演


依托于用户喜爱的世界观或角色，系统将扮演用户喜爱的角色来为用户提供交流服务，使得本系统更具趣味性与个性化；如我比较喜欢打王者荣耀，那么系统将会扮演王者荣耀里面的妲己角色来为用户讲解枯燥的知识点。

技术实现

框架概述

采用前后端分离模式，整体架构分为前端、后端和数据库三层。

- 前端：登录注册、个人中心、聊天界面、题目练习
- 后端：用户请求、调用大语言模型、管理数据库交互
- 数据库：RAG 内容存储，对话内容存储，世界观/知识点回复存储



技术亮点

- **React** 框架：简化聊天界面的编写，以组件化开发和高效的状态管理，快速书写前端
- **RAG / 数据增强**：用A内容来讲解B内容，找到两个看似毫不相干的A和B之间的相似性，来进行类比性讲解，是连我们人类都觉得很难的事情。但是利用大模型强大的自然语言处理分析的能力，并且通过结合**智能体检索增强生成Agentic RAG**和**纠错检索增强生成Corrective RAG (CRAG)**，使得大模型获取到关于A和B的高质量信息，让大模型从A内容和B内容之间找到共同点，做到我们人类也很难做到的类比。

- 智能体检索增强生成 **Agentic RAG**

智能体 **Agent** 接收用户查询，能感知到和用户的历史交互，可以选择使用哪种工具，综合决定适当的行动路线。起到一个整体的宏观调度的作用。

- 纠错检索增强生成 **Corrective RAG (CRAG)**

使用评估器对检索文档的相关性进行评估，只保留相关性通过检验的文档，确保在生成过程中使用更准确可靠的信息，如果经过评估没有相关性能通过检验的文档，则需要再搜索外部信息来找到可靠的信息。进一步减少幻觉。

为什么要用RAG? 减少幻觉问题。检索增强生成 (RAG) 是一种用于构建LLM驱动的应用程序的技术。它利用外部知识源为LLM提供相关上下文来减少幻觉。


- `weaviate` 向量化数据库: 作为分布式集群数据库可以迅速搜索相似向量, 同时因为其云原生特性保证了项目的健壮性与鲁棒性; 在项目中用作存储世界观与知识点, 以及生成的反馈结果相关文本, 用于关键词搜索复用增强大模型生成内容的准确性。

```
import weaviate
client = weaviate.connect_to_local()
```

- `LangChain` 框架
 - `langGraph` 搭建模型的逻辑流程, 重写了 `MessageState` 来支持更丰富的状态传递
 - `Tool calling` 模块赋予模型调用工具的能力

```
model = model.bind_tools(tools), 具体来说我们用了 langchain Toolset 里的搜索引擎 Google Serper api 来进行搜索
```
 - `LangChain` 支持的 `vector_store` 和 `openAI` 的 `embedding` 模型来进行搜索内容的向量化存储和相似性搜索
 - `ConversationChain` 和 `ConversationBufferMemory` 来实现和用户的交互式有记忆的对话
 - 在调试时使用 `LangChain` 的 `Traceable` 来监视输入在图中的每一个节点后的变化

```
from langchain_openai import ChatOpenAI, OpenAIEmbeddings
from langchain_core.vectorstores import InMemoryVectorStore
from langchain_community.utilities import GoogleSerperAPIWrapper
```



用户输入问题“用A解释B”，智能体 agent 综合已有的增强文件、用户对话上下文来决定是否去调用工具来补充增强文本，如果调用工具的话是调用哪个工具，信息是否足够到可以跳到 generate 节点去生成回答。这就是 ***智能体检索增强生成*** 的思想。

智能体 Agent 可以调用的 toolset 中包含一个数据库检索工具 retriever 和一个搜索引擎工具 web_search，数据库检索工具 retriever 会利用余弦相似度从保存了相关文档的数据库中检索出和输入A和B最相关的文档；搜索引擎工具 web_search 会从网页搜索和A、B相关的文档并存入数据库中。

然后对收集到的增强文本进行过滤，使用评估器 grade_documents 进行评估，只保留相关性通过检验的文档，这是 ***纠错检索增强生成*** 的思想。

评估器 grade_documents 则仅将这些通过检验的文档返回给 Agent，然后 Agent 决定是否现在回答问题还是继续寻找增强文档。如果 Agent 认为增强文本足够了，那么跳到 generate 节点进行回答生成。


- **Docker 部署**：采用 Docker 进行部署，将 MySQL、web 服务和 weaviate 向量数据库分别打包为容器，实现服务解耦，提高容错性

成果展示

展示视频见：<https://pan.baidu.com/s/1jiTjw9Kgaf6iS47eV1OPgA?pwd=z7i9> 提取码: z7i9

项目总结

就调查而言，在市场上，还没有成形的大规模应用形似我们功能的软件。因此，我们的项目在教育市场有着广阔的商业前景和潜在的市场价值，无论是**生成教案还是自主学习**都能够提供一定的帮助，作为一种创新的学习工具，针对学生对学习感到枯燥乏味的心理，寓教于乐，帮助学生轻松掌握晦涩的专业知识。



团队分工

陈蔚竹：应用设计、数据库设计/实现、前端实现、文稿撰写

王菲：Flask 框架搭建、Docker 部署

李涵一：LangChain 模型设计/实现

李莲鑫：UI 设计、前端实现、文稿撰写

鸣谢

助教：[Qi-ming-Zhang](#)、[zhangjiarui530](#)

指导老师：[AliceCodeZhang](#)

技术指导：王逸婷